

灵小禅

面向真实景区复杂场景的 AI 数字人导游

融合多路知识检索 · 游客状态理解 · 多约束路线规划

让 AI 从「回答旅游问题」进一步走向「理解游客、规划行程、辅助游览决策」



传统景区导览难以处理复杂、动态、个性化的游客需求

//

“我带着 70 岁的父母，只有 3 小时，应该怎么游览？”

普通 FAQ 只有景点介绍，没有时间预算与多景点取舍

//

“14:30 有演出，我现在在某个景点，下一站去哪？”

传统导览不感知当前位置与演出场次的动态衔接

//

“附近有没有适合轮椅通行的路线和卫生间？”

通用大模型没有景区事实，也无行动能力与设施约束

景区智能导览真正面对的是 —— 多个问题同时存在

景区知识

游客个体状态

时间约束

空间约束

游览决策

单一「问答式」工具无法覆盖——景区需要的是一个会检索知识、会理解游客、会规划路线的智能体。

真正的智能导游，需要同时解决「知识、理解、决策」三个问题

01

Knowledge

知道景区

多路混合 RAG

可靠获取景区知识
语义 · 专名 · 结构化事实

02

Understanding

理解游客

场景状态解析

感知个体约束
时间 · 行动能力 · 偏好

03

Decision

规划游览

多约束路线规划

生成可执行决策
满足硬约束与时间线

AI 数字人导游

理解游客 → 检索知识 → 辅助决策

构建覆盖「问—懂—查—规划—交互」的 AI 导游闭环



一句话方案

游客的自然语言需求先被解析为结构化状态，再通过「多路检索拿事实 + 确定性规划算路线」，最后由大模型组织成有温度的回答——每一步都有据可查。

支撑层（辅助信息，不构成创新点）

Express · TypeScript

React 19 · Ant Design

ChromaDB + BGE 中文模型

edge-tts · ASR

Live2D 数字人

DeepSeek / Agnes LLM

后端框架、数据库与中间件只是支撑层；核心价值在中间「懂—查—规划」智能链路。

多路混合 RAG：让不同性质的问题走不同的信息通道

检索流水线

游客问题

口语化 · 多约束 · 混合表达

问题分析 / Router

判断问题性质，决定检索通道

三路并行检索

Vector · Keyword · Structured

RRF 统一候选 + Rerank

k=60 融合，精排上下文

Evidence → LLM 生成

带证据的回答 + 完整 Trace

不同问题 → 不同通道（真实映射）

Vector 语义召回

“梵宫有多大规模？”

语义 / 同义表达

BGE 中文向量，处理说法差异

Keyword 精确命中

“百子戏弥勒”在哪个区域？

精确专名 / 编号

专名、短词、原文命中不漂移

Structured 字段级

《吉祥颂》14:00 场次多久？

结构化事实

时刻 · 时长 · 票价 · 开放窗口

创新不是「用了 RAG」，而是为不同类型的事实设计互补检索通道，并用 Trace 证明每路真实执行、召回了什么、如何影响最终回答。


单一向量检索存在盲区：不同问题需要不同的信息获取机制

“灵山大佛有多高？” 语义 • 常见问答	单一向量检索的盲区 向量可召回相似问法，但缺少精确事实对齐	✓ 对应通道 Vector 语义召回
“百子戏弥勒” 在哪个区域？ 精确专名	单一向量检索的盲区 近义词干扰下，向量可能被语义「带偏」	✓ 对应通道 Keyword 精确命中
《吉祥颂》 14:00 场次演出多长时间？ 结构化事实	单一向量检索的盲区 向量难以稳定对齐「时刻 · 时长」字段	✓ 对应通道 Structured 字段级保证

多路检索的价值：为不同类型的事实设计互补通道，减少「看似相关、实则漏检」，让回答有证据可依。

完整检索链在 50 题测试集上达到 98.0% 准确率

检索方式消融 (Accuracy %)



组件消融 (同一测试集)

98.0%

Full Retrieval

完整链路

90.0%

Full – Rerank

Rerank 贡献 +8.0pp (本轮观察)

98.0%

Full – Rewrite

Rewrite 本轮无差异 (Trace 复核)

控制变量: 同一 50 题测试集 · 同一模型 (请求 deepseek-chat, Provider trace 返回 deepseek-flash) · 同一 Prompt / 参数 · 每题独立 session · retrievalTopK=8 / contextTopK=5
· 单变量消融, 7 组 × 50 题 = 350 次真实 API 调用

让 AI 理解「游客是谁、想去哪、还有多少时间」

真实游客输入

“我带腿脚不方便的妈妈，现在是 13:00，在景区入口，只有三小时，还想看两点的《吉祥颂》，应该怎么走？”

一段自然语言里同时包含：同行人的、行动能力、当前时间、时间预算、演艺偏好、当前位置——这正是真实游客的说话方式。

系统解析出的 Scene State（结构化游客状态）

当前地点 南门入口（ south_gate ）	当前时间 13:00
剩余时间 180 分钟	同行人的 老人（ with_elderly ）
行动能力 行动受限（ limited ）	演艺偏好 《灵山吉祥颂》 14:00
必去 / 已游景点 由需求与路线引擎共同维护	缺失关键字段 无 —— 若缺失则主动追问

结构化字段 currentLocation • currentTime • remainingMinutes • partyType • mobility • interests • mustVisit • preferredPerformance • visited • missingCriticalFields

关键：系统形成可复用的「游客状态」，而不是只做一次性问答；信息不足时用自然语言追问，不猜不编。

路线生成由真实约束驱动，而不是模型「随口推荐」

约束输入 → 确定性规划

必去景点

时间预算

当前位置

行动能力 / 无障碍

演艺场次与时长

已游景点 • 开放窗口

Constraint Planner (确定性图搜索 + 校验)

LLM 负责理解与解释，但「路线可行」由算法裁决 —— 模型不能绕过硬约束宣布一条路线可行

- 多段路径 + 步行时长
- 到达 / 等待 / 演出时间线
- 硬约束满足证明
- 不可行 → 拒绝并给替代方案

真实路网与验证结果



灵山梵宫（《吉祥颂》演出地，LS-013）

- 23 个景点 POI
 - 2 场演艺（时刻 • 时长）
- 30 条路网边
 - 3 类设施

60/60

可行性分类正确

0

硬约束违规 hard violations

1.0

不可行 P / R / F1

确定性可复现：核心路线重复执行 9 次结果一致。步行时长等字段标记 estimated，需现场核验后才能称为运营级导航。

建立覆盖「知识—理解—决策」的系统化评测体系

① RAG / Knowledge

96.0%

48 / 50 通过

- 50 题 Fact Contract 评测
- Fact recall 0.970
- Retrieval success 50/50
- 失败题保留，不隐藏

真实 QA API · 每题独立 session

② Scene Understanding

40 / 40

field accuracy 1.0

- 老人 / 儿童 / 轮椅 / 行动受限
- 时间约束 · 演艺偏好
- 必去 / 已游景点
- 缺失关键字段识别

确定性场景抽取 · gold case

③ Route Planning

60 / 60

hard violations = 0

- 可行性分类全部正确
- 不可行 P / R / F1 = 1.0
- 10 组不可行用例诚实拒绝
- 确定性重复执行一致

结构化约束验证

评测证据链（全部版本化）

Fact Contract

Retrieval Gold

Scene Gold

Route Validator

Runtime Smoke

Ablation

离线评测 ≠ 用户满意度；路线为结构化约束验证，步行时长标记 estimated。项目后续计划补充真实游客研究与运营方数据核验。

一个复杂游客请求：三个创新如何协同完成

游客输入

“我带腿脚不方便的妈妈，现在是 13:00，在景区入口，只有三小时，还想看两点的《吉祥颂》，应该怎么走？”

创新二

① 游客状态解析

Scene State：老人 · 行动受限 · 剩余 180 分钟 · 演艺偏好《吉祥颂》14:00

创新一

② 景区知识检索

多路 RAG：演出时刻与时长 · 景点开放窗口 · 位置关系 · 无障碍信息

创新三

③ 约束规划

确定性搜索：多段路径 + 到达 / 等待 / 演出时间线，满足全部硬约束

交互

④ LLM 生成解释

为什么这么走 · 预计耗时 · 下一站 · 注意事项

对照：系统如何处理「不可行」与「信息不足」？

同样 3 小时但 10:00 出发 → 14:00 演出不可达：系统诚实拒绝，并给出满足时间预算的替代路线，不把需求「包装成可行」。

缺失当前时间 → 系统主动追问「你现在大约几点开始游览？」；缺失位置 → 继续澄清。不猜测、不编造、不留错误码。

核心 AI 能力已封装为可实际交互的数字人导游

- 1

数字人交互

Live2D 实时渲染 · 口型同步 · 表情动作
- 2

语音问答

语音输入识别 + 语音播报，解放双手
- 3

智能问答

多路混合 RAG 流式回答，带证据可溯源
- 4

路线推荐

约束路线规划 + 地图 + 周边设施推荐

辅助功能

- 景点百科

周边设施

图片识别
- 情感分析

字人


管理后台



灵小禅 · 数字人导游 (Live2D)

数字人是产品表现层，核心价值在背后的理解与决策链路

核心能力可从单一景区复制到更多文旅空间



灵山胜境（首个落地景区）

已验证：50 题评测 · 场景 40/40 · 路线 60/60 · 真实产品闭环

景区专属资产：知识库 · 23 个 POI · 30 条路网边 · 演艺时刻 · 设施规则——全部数据与算法解耦，配置驱动。

可扩展的文旅空间

古镇	博物馆	主题园区
景区	校园	文旅综合体

同一套「数据配置 + 核心算法 + 交互层」骨架，替换知识库、POI、路线图与景区规则即可快速适配新场景。

需要替换（场景专属）

- 知识库语料
- POI / 路网 / 演艺

景区规则与设施工程化设计（数据与算法解耦、配置驱动、评测可复现）是可迁移性的基础；不依赖任何单点景区数据。

核心能力复用（不依赖具体景区）

- Hybrid RAG 多路检索
- Scene Understanding 场景解析
- Constraint Planning 约束规划
- AI 交互与证据链评测

让 AI 导游从「回答问题」走向「理解游客并辅助游览决策」

Hybrid RAG

可靠获取景区知识

多路检索 · 证据可溯源

Scene Understanding

理解个体需求

结构化游客状态 · 缺信息追问

Constraint Planning

完成复杂游览决策

确定性规划 · 硬约束裁决

最有说服力的三个真实实验数字

98.0%

完整检索链准确率 (50 题消融)

40 / 40

场景理解 Gold 用例全部通过

60 / 60 · 0

路线可行性分类 · 硬约束违规

我们希望让 AI 真正理解游客当前需求，并基于可信景区知识与现实约束，辅助游客完成一次完整的游览决策。