

灵小禅

面向真实景区复杂场景的 AI 数字人导游

融合多路知识检索 · 游客状态理解 · 多约束路线规划

让 AI 从「回答旅游问题」进一步走向「理解游客、规划行程、辅助游览决策」

项目仓库 github.com/Mao123-doc/lingshan-ai-guide | 全国总决赛汇报
· 2026.09

全部实验数据来自仓库 [evaluation/results](#) 真实记录，未虚构指标



传统景区导览难以处理复杂、动态、个性化的游客需求

“我带着 70 岁的父母，限时 5 小时，怎么游览？”

🔔【物理拓扑盲区】

普通 FAQ 缺乏坡度与台阶模型，盲目推荐轮椅攀登 216 级长阶天梯！

“14:30 有演出，我现在在正门，怎么去梵宫？”

🔔【时空时效错配】

正门至梵宫 1.4km (步行需 22min)，演出提前 15min 停检，盲目推荐导致游客狂奔依然扑空！

“灵山大佛门票多少钱？20 分钟能游览完吗？”

🔔【事实数值幻觉】

门票全票 210 元非 50 元；20 分钟根本无法游园，大模型过度谄媚强行编造！

景区智能导览真正面对的是 —— 多个问题同时存在

景区知识

游客个体状态

时间约束

空间约束

游览决策

- 【探索性预调研 n=50，不外推至全部游客】：
- 82.0% (41/50) 曾因排队错过演艺
 - 66.0% (33/50) 遭遇台阶陡坡折返（行动受限样本 93.3%，28/30）
 - 74.0% (37/50) 曾遭遇通用大模型事实幻觉
 - 90.0% (45/50) 表达使用意愿！

真正的智能导游，需要同时解决「知识、理解、决策」三个问题

01

Knowledge

知道景区

多路混合 RAG

可靠获取景区知识
语义 · 专名 · 结构化事实

02

Understanding

理解游客

场景状态解析

感知个体约束
时间 · 行动能力 · 偏好

03

Decision

规划游览

多约束路线规划

生成可执行决策
满足硬约束与时间线

AI 数字人导游

理解游客 → 检索知识 → 辅助决策

构建覆盖「问—懂—查—规划—交互」的 AI 导游闭环



一句话方案

游客的自然语言需求先被解析为结构化状态，再通过「多路检索拿事实 + 确定性规划算路线」，最后由大模型组织成有温度的回答——每一步都有据可查。

支撑层（辅助信息，不构成创新点）

Express · TypeScript

React 19 · Ant Design

ChromaDB + BGE 中文模型

edge-tts · ASR

Live2D 数字人

DeepSeek / Agnes LLM

后端框架、数据库与中间件只是支撑层；核心价值在中间「懂—查—规划」智能链路。

多路混合 RAG：让不同性质的问题获得互补证据

检索流水线

游客问题

口语化 · 多约束 · 混合表达

问题分析 / Query Analysis
识别问题类型，仅用于 Trace 标注与结果解释

三路并行检索

Vector · Keyword · Structured

RRF 统一候选 + Rerank

k=60 融合，精排上下文

Evidence → LLM 生成

带证据的回答 + 完整 Trace

不同问题 → 不同解释重点（三路并行召回）

Vector 语义召回

“梵宫有多大规模？”

语义 / 同义表达

BGE 中文向量，处理说法差异

Keyword 精确命中

“百子戏弥勒”在哪个区域？

精确专名 / 编号

专名、短词、原文命中不漂移

Structured 字段级

《吉祥颂》14:00 场次多久？

结构化事实

时刻 · 时长 · 票价 · 开放窗口

创新不是「用了 RAG」，而是为不同类型的事实设计互补检索通道，并用 Trace 证明每路真实执行、召回了什么、如何影响最终回答。


单一向量检索存在盲区：不同问题需要不同的信息获取机制

“灵山大佛有多高？” 语义 · 常见问答	单一向量检索的盲区 向量可召回相似问法，但缺少精确事实对齐	✓ 对应通道 Vector 语义召回
“百子戏弥勒” 在哪个区域？ 精确专名	单一向量检索的盲区 近义词干扰下，向量可能被语义「带偏」	✓ 对应通道 Keyword 精确命中
《吉祥颂》14:00 场次演出多长时间？ 结构化事实	单一向量检索的盲区 向量难以稳定对齐「时刻 · 时长」字段	✓ 对应通道 Structured 字段级保证

多路检索的价值：为不同类型的事实设计互补通道，减少「看似相关、实则漏检」，让回答有证据可依。


权威基线 96.0% (48/50) | 受控消融完整方案单次观察值 98.0%

检索方式消融 (Accuracy %)



7 组受控消融 (同一 50 题测试集)

组件消融 (同一测试集)



98.0% = Full retrieval / Full - Rewrite 的单次受控运行观察值; 权威基线仍为 96.0% (48/50)。

让 AI 理解「游客是谁、想去哪、还有多少时间」

真实游客输入

我带腿脚不方便的妈妈，现在在正门，预计下午四点前返程（限时5小时），还想看两点的《吉祥颂》，怎么走？

一段自然语言里同时包含：同行人的、行动能力、当前时间、时间预算、演艺偏好、当前位置——这正是真实游客的说话方式。

系统解析出的 Scene State（结构化游客状态）

当前地点 南门入口 (south_gate)	当前时间 11:00
剩余时间 300 分 (5小时)	同行人的 老人 (with_elderly)
行动能力 行动受限 (limited)	演艺偏好 《灵山吉祥颂》 14:00
必去 / 已游景点 由需求与路线引擎共同维护	缺失关键字段 无 —— 若缺失则主动追问

13维状态向量：currentLocation (正门) · currentTime (11:00) · remainingMinutes (300) · deadline (16:00) · partyType (elderly) · mobility (limited) · mustVisit · preferredPerformance (吉祥颂14:00, 缓冲20min) · visited · missingCriticalFields

关键：系统形成可复用的「游客状态」，而不是只做一次性问答；信息不足时用自然语言追问，不猜不编。

路线生成由真实约束驱动，而不是模型「随口推荐」

约束输入 → 确定性规划

必去景点

时间预算

当前位置

行动能力 / 无障碍

演艺场次与时长

已游景点 • 开放窗口

运筹规划内核：Dijkstra 空间过滤 + 24 宽 Beam Search + 14 项 Route Validator

LLM 负责理解与解释，但「路线可行」由算法裁决 —— 模型不能绕过硬约束宣布一条路线可行

- 无障碍子图过滤 (坡度 < 2.5° 剔除台阶)
- 演艺前置 15~20min 安检排队缓冲 + 倒排调度
- 14 项形式化守恒仲裁器 (0 硬违规放行)
- 不可行 → 拒绝并给替代方案

【23 个路线节点 + 30 条当前登记道路边 (31 条目标口径待补齐核验)】：60 组边界案例测试 100% (60/60) 形式化合规，物理硬违规恒为 0！
确定性可复现：核心路线重复执行 9 次完全一致。部分小径步行时长标记为 estimated 预估值，体现学术严谨自省。

真实路网与验证结果



灵山梵宫 (《吉祥颂》演出地, LS-013)

• 23 个景点 POI

• 2 场演艺 (时刻·时长)

▪ 30 条当前登记道路边
(31 条目标口径待补齐
核验)
3 类设施

60/60

可行性分类正确

0

硬约束违规 hard violations

1.0

不可行 P / R / F1

建立覆盖「知识—理解—决策」的系统化评测体系

① RAG / Knowledge

96.0%

48 / 50 通过

- 50 题 Fact Contract 评测
- Fact recall 0.970
- Retrieval success 50/50
- 失败题保留，不隐藏

真实 QA API · 每题独立 session

② Scene Understanding

40 / 40

field accuracy 1.0

- 老人 / 儿童 / 轮椅 / 行动受限
- 时间约束 · 演艺偏好
- 必去 / 已游景点
- 缺失关键字段识别

确定性场景抽取 · gold case

③ Route Planning

60 / 60

hard violations = 0

- 可行性分类全部正确
- 不可行 P / R / F1 = 1.0
- 10 组不可行用例诚实拒绝
- 确定性重复执行一致

结构化约束验证

评测证据链（全部版本化）

Fact Contract

Retrieval Gold

Scene Gold

Route Validator

Runtime Smoke

Ablation

离线评测 ≠ 用户满意度；路线为结构化约束验证，步行时长标记 estimated。项目后续计划补充真实游客研究与运营方数据核验。

典型场景实测：限时 5 小时带老人看演出游大佛 2.5D 物理动线复盘

游客输入

我带腿脚不方便的妈妈，现在在正门，预计下午四点前返程（限时5小时），还想看两点的《吉祥颂》，怎么走？

11:00 正门启程

11:50 抵达九龙灌浴

无障碍平缓坡道 (坡度 $1.8^{\circ} < 2.5^{\circ}$) · 步行 420m / 8min · 观演 30min · 自动过滤天梯

12:30 动态纠偏

秒级动态增量纠偏

拍照超时 10min · 自动压缩非核心林道漫步 10min · 锁定 16:00 离园与 14:00 演出死线

13:40 梵宫检票

前置 20min 缓冲

前置 20 分钟排队安检缓冲 · 顺利入场观看 14:00~14:20 《吉祥颂》· 24 宽 Beam Search 严格对齐

15:10 无障碍电瓶车接驳

16:00 准时返正门（全程 300min）

避开陡坡登顶直达大佛 · 14 项形式化守恒仲裁通过检查 · 总耗时 300 分钟 · 当前结构化约束测试中 0 次物理硬违规

【诚实拒绝与优雅降级】

- 20 分钟无法同时完成正门往返与 14:00 演出，系统拒绝编造路线；
- 自动剥离演艺偏好，生成正门广场与佛足坛微游览方案（18min），保留可执行替代。

主动澄清机制已在 P8 展示：缺失时间或位置时先追问，不猜测、不编造。

产品工程落地：双屏架构分流 + 证据追溯抽屉 + 202.4 QPS 纯规划吞吐

1

左屏 · QAPage (事实问答)

Live2D 情绪驱动 (倾听/欢喜/致歉) · 实时渲染 · 口型同步

2

证据追溯抽屉 (Evidence Drawer)

出处、向量相似度 0.89、时延 2.88s · 语音识别播报

3

右屏 · RecommendPage (决策看板)

物理时空动线看板 (米数、坡度、无障碍) · 流式回答

4

实景导航无缝串联

一键原生调起高德/百度地图 SDK 闭环 · 约束路线推荐

【硬核工程交付指标与实测性能】

- 🖥️ 边云协同实测：单台 4 核 8G 纯规划接口 (/api/route/plan) 实测 202.4 QPS 吞吐 (P50=7.8ms, P95=13.4ms, 0 错误率；线程池隔离，不含 LLM/ASR/TTS/图像识别全链路)
- 📦 轻量离线容灾：核心路网拓扑仅 35KB (23 节点 + 30 条登记边；31 条目标待核验)，支持客户端秒级离线加载与应急动线渲染
- 💰 极低运维成本：年综合运维成本约 1.39 万元 (<1.5 万元/年；一次性实施 5.0 万元独立核算)，情景模型预计 3~6 个月收回投入 (情景假设测算)



灵小禅 · 数字人导游 (Live2D)

推广应用价值：三阶轻量化落地与情景 ROI 模型



灵山胜境（首个落地景区）

已验证：50 题评测 · 场景 40/40 · 路线 60/60 · 真实产品闭环

景区专属资产：知识库 · 23 个路线节点 · 30 条当前登记道路边（31 条目标待核验） · 演艺时刻 · 设施规则——全部数据与算法解耦，配置驱动。

需要替换（场景专属资产 · 配置驱动）

- 知识库语料（官方指南与典故）
- 23 个路线节点 + 30 条当前登记道路边（31 条目标待核验）
- 演艺时刻、观光车时刻与设施规则

三阶轻量化务实落地体系 (时间轴)



- 第一阶段 · 轻量版 (1 周 · 零测绘)：基于现有矢量导览图提取 23 景点路网契约 (2~3 人天)，导入导游词，极速上线智能问答与基础游览；
- 第二阶段 · 标准版 (2 周 · 动态协同)：对接演艺排期与观光车时刻，开启多约束时空规划与 14 项守恒仲裁器；
- 第三阶段 · 深度数智版 (4 周 · 深度融合)：接入闸机客流与高精测绘，实现全园动态客流削峰填谷。

商业财务测算（情景假设）

- 💰 年运维：1.39 万元；首次实施：5.0 万元（独立核算）
- 📈 闭环：SaaS 服务费 + 个性化交付 + 二消/观光车分成
- 🎯 ROI：3~6 个月回收投入（中性情景 4.8 个月；非已实现经营结果）

以算法敬畏物理世界，用数智赋能华夏文旅：灵小禅可信文旅决策智能体

Hybrid RAG

可靠获取景区知识

多路检索 · 证据可溯源

Scene Understanding

理解个体需求

结构化游客状态 · 缺信息追问

Constraint Planning

完成复杂游览决策

确定性规划 · 硬约束裁决

最有说服力的三个真实实验数字

96.0%

Fact Contract 权威基线准确率 (50 题基准)

40 / 40

场景理解 Gold 用例全部通过

60 / 60 • 0

路线可行性分类 · 物理硬违规恒为 0

我们希望让 AI 真正理解游客当前需求，基于可信景区知识与现实约束，辅助游客完成一次完整的游览决策。

* 严格说明：98.0% 为 7 组受控消融实验中 Full Retrieval 单次运行观察值，系统冻结权威基线统一为 96.0% (48/50)。